



ESERCITAZIONE FINALE
MODULO 2

STATISTICA RIGOROSA & EXCEL

CORSO AI DATA ANALISYS

SCENARIO, DATASET E OBIETTIVI DELL'ANALISI

Scenario

La Regione Marche richiede un'analisi del patrimonio ricettivo regionale, partendo da due fonti distinte:

- elencostrutture.xlsx, contenente le informazioni anagrafiche delle strutture;
- prezzimedi.xlsx, contenente il prezzo medio per notte associato alle diverse città.

Dimensione dei dati

- 6.259 righe iniziali nel file delle strutture, inclusa l'intestazione;
- 6.258 strutture ricettive effettive;
- 234 città;
- 15 categorie di struttura;
- una rilevazione del prezzo medio per ciascuna città.

Problema iniziale

I dati non erano immediatamente utilizzabili perché presentavano:

- righe iniziali non pertinenti nel file dei prezzi;
- celle vuote;
- possibili duplicati;
- differenze nella scrittura delle località;
- dati distribuiti in due file separati;
- necessità di collegare ogni struttura al prezzo medio della relativa città.

Obiettivo dell'analisi

Costruire un dataset unico, pulito e coerente per:

1. analizzare la distribuzione delle strutture;
2. creare strumenti di ricerca e filtro;
3. descrivere statisticamente i prezzi;
4. individuare valori anomali;
5. stimare intervalli e probabilità;
6. confrontare categorie differenti;
7. verificare la relazione tra numero di strutture e prezzo medio.

IMPORTAZIONE E PULIZIA DEI DATI CON POWER QUERY

Obiettivo

Preparare i due dataset per renderli affidabili e pronti all'analisi.

Perché Power Query?

Power Query è uno strumento ETL (Extract – Transform – Load).

La caratteristica principale è che tutte le trasformazioni vengono registrate come Passaggi Applicati, rendendo il processo:

- ripetibile;
- aggiornabile;
- non distruttivo.

01.

Extract (Estrazione):
importazione dei dati
dai file Excel.

02.

Transform
(Trasformazione):
pulizia e
standardizzazione.

03.

Load (Caricamento):
caricamento nel
modello dati.

OPERAZIONI EFFETTUATE

01

Importazione dei due file

Sono stati importati:

- elencostrutture.xlsx
- prezzimedi.xlsx

02

Pulizia del file prezzi

Il dataset presentava alcune righe iniziali che non rappresentavano dati.

Sono state quindi:

- eliminate le righe non valide;
- promossa la prima riga ad intestazione.

03

Impostazione dei tipi di dato

Sono stati assegnati i tipi corretti. Perché Excel interpreta in modo diverso numeri e testo.

Un prezzo salvato come testo impedisce:

- calcolo della media;
- deviazione standard;
- regressione;
- correlazione.

04

Standardizzazione del dataset

Sono state corrette le differenze di scrittura:

- spazi iniziali e finali;
- maiuscole/minuscole
- celle vuote;
- uniformità dei nomi delle città.

Perché?

Il Merge funziona solo se la chiave è identica.

Risultato ottenuto

Due tabelle pulite e pronte per essere collegate.

Non sono state utilizzate formule Excel.

Le operazioni sono state eseguite tramite:

- Rimuovi righe
- Promuovi intestazioni
- Cambia tipo
- Trim
- Clean
- Sostituisci valori

Power Query traduce automaticamente tutto nel linguaggio M.

Merge delle tabelle

Obiettivo

Associare ad ogni struttura ricettiva il prezzo medio della città.

Il Merge rappresenta una delle operazioni più importanti di Power Query.

Attraverso la colonna Città ho collegato i due dataset utilizzando un Left Outer Join. In questo modo ogni struttura ricettiva ha acquisito il prezzo medio della città mantenendo comunque tutte le strutture presenti nella tabella originale.



RAGGRUPPAMENTO DEI DATI (GROUP BY)

Obiettivo

Ottenere dati sintetici da utilizzare nelle analisi.

Operazione
Power Query



Group By

Sono stati creati due riepiloghi

Conteggio per città

Numero di strutture presenti in ogni città.

Conteggio per categoria

Numero di strutture appartenenti ad ogni categoria.

Perché usare Group By?

Permette di trasformare migliaia di righe in indicatori sintetici.

Ad esempio

6258 righe



234 città



15 categorie

Perché non usare una Pivot?

Perché il raggruppamento è stato creato direttamente nella fase ETL.

In questo modo il riepilogo si aggiorna automaticamente ad ogni aggiornamento della query.

Risultato

Sono state ottenute due tabelle fondamentali che verranno utilizzate nelle analisi statistiche successive.

Qual è la differenza tra Merge e Group By?

- Merge unisce informazioni provenienti da tabelle diverse.
- Group By aggrega i dati della stessa tabella producendo statistiche come conteggi, somme o medie.

RICERCA DATI CON CERCA.VERT

Automazione della ricerca delle informazioni

Obiettivo

Creare una maschera di ricerca che permetta di recuperare automaticamente le informazioni di una struttura ricettiva partendo dalla sua denominazione.

Problema

Il dataset contiene migliaia di strutture ricettive. Ricercare manualmente città, indirizzo, sito web o e-mail avrebbe comportato:

- elevata probabilità di errore;
- tempi di ricerca elevati;
- difficoltà nell'aggiornamento dei dati.

Soluzione

È stata utilizzata la funzione:
=CERCA.VERT(valore;tabella;indice_colonna;FALSO)

Nel progetto la formula è stata adattata ai riferimenti reali del foglio "Strutture ricettive" per recuperare automaticamente le informazioni richieste.

Perché usare CERCA.VERT?

Permette di:

- automatizzare la ricerca delle informazioni;
- evitare inserimenti manuali;
- aggiornare automaticamente i risultati quando cambia il database.

Limiti della funzione

CERCA.VERT funziona correttamente solo se:

- il valore cercato è presente nella prima colonna della tabella;
- la ricerca è esatta (FALSO);
- i dati sono stati preventivamente puliti e uniformati.

Per questo motivo la fase di pulizia eseguita in Power Query è stata fondamentale.

Risultato

- Inserendo il nome di una struttura nella maschera di ricerca vengono recuperati automaticamente: città; indirizzo; sito web; e-mail; altre informazioni presenti nel database.

CONTEGGIO DELLE STRUTTURE

Analisi della distribuzione delle strutture ricettive

Obiettivo

Comprendere come sono distribuite le strutture nel territorio.

Sono stati creati due riepiloghi.

Conteggio per categoria

Calcola quante strutture appartengono ad ogni tipologia.

Esempio

- Alberghi
- Bed & Breakfast
- Agriturismi
- Campeggi

Conteggio per città

Calcola quante strutture sono presenti in ciascun comune.

Perché è importante?

Questa analisi permette di individuare:

- le categorie predominanti;
- le città con maggiore concentrazione di strutture;
- la distribuzione dell'offerta ricettiva.

Come è stato ottenuto?

Le tabelle sono state create tramite Group By in Power Query.

Il raggruppamento conta automaticamente le righe appartenenti allo stesso gruppo.

Risultato

Sono stati ottenuti:

- 15 categorie;
- 234 città.

Queste tabelle sono diventate la base per tutte le analisi successive.

Interpretazione

L'aggregazione consente di trasformare migliaia di osservazioni in informazioni sintetiche facilmente interpretabili.

FILTRO DINAMICO PER CITTÀ

Consultazione dinamica delle strutture

Obiettivo

Realizzare uno strumento che permetta di selezionare una città e visualizzare automaticamente tutte le strutture presenti.

Strumenti utilizzati

Sono state impiegate le funzioni dinamiche di Excel.

Tra queste:

- UNICI
- FILTRO
- ORDINA

Funzionamento

L'utente seleziona una città.

Excel aggiorna automaticamente:

- elenco strutture;
- categoria;
- indirizzo;
- località;
- sito internet;
- email;
- prezzo medio.

Perché realizzarlo?

Consente una consultazione immediata del patrimonio ricettivo senza applicare filtri manuali. È un esempio di dashboard dinamica.

Vantaggi

- aggiornamento automatico;
- eliminazione delle ricerche manuali;
- maggiore velocità di consultazione;
- possibilità di estendere facilmente il modello.

ANALISI DESCRITTIVA DEI PREZZI

Analisi descrittiva della distribuzione dei prezzi medi

Obiettivo

Descrivere il comportamento dei prezzi medi delle strutture ricettive nelle città delle Marche attraverso gli indicatori di statistica descrittiva.
Questa fase rappresenta il primo passo di qualsiasi analisi statistica, perché permette di comprendere la distribuzione dei dati prima di applicare test o modelli.

Indicatori calcolati

Indicatore	Formula Excel	Significato
Media	<code>=MEDIA()</code>	Valore medio dei prezzi.
Mediana	<code>=MEDIANA()</code>	Valore centrale della distribuzione.
Moda	<code>=MODA()</code>	Prezzo che compare più frequentemente.
Varianza	<code>=VAR.P()</code>	Misura la dispersione dei dati rispetto alla media.
Deviazione standard	<code>=DEV.ST.P()</code>	Indica quanto, mediamente, i prezzi si discostano dalla media.
IQR	<code>=QUARTILE.INC(Q3)- QUARTILE.INC(Q1)</code>	Misura la dispersione del 50% centrale dei dati.

ANALISI DESCRITTIVA DEI PREZZI

Risultati ottenuti

Dal dataset sono stati calcolati:

- Media = 73,5 €
- Mediana = 73,5 €
- Moda = 75 €
- Varianza = 754,06
- Deviazione standard = 27,46
- IQR = 51,5

Interpretazione Media e mediana

Il fatto che coincidano indica che la distribuzione dei prezzi è sostanzialmente simmetrica. Non emerge una forte asimmetria verso prezzi molto elevati o molto bassi.

Moda

La moda pari a 75 € rappresenta il prezzo che compare più frequentemente nel campione.

Deviazione standard

Una deviazione standard di 27,46 € indica una discreta variabilità dei prezzi. Ciò significa che i prezzi non sono tutti concentrati intorno alla media, ma presentano differenze significative tra le città.

IQR

L'intervallo interquartile di 51,5 € descrive la dispersione del 50% centrale dei dati. Essendo meno influenzato dai valori estremi rispetto alla deviazione standard, rappresenta una misura robusta della variabilità.

DISTRIBUZIONE DEI PREZZI

Distribuzione di frequenza dei prezzi medi

Obiettivo

Suddividere i prezzi in classi per comprendere come si distribuiscono nel campione.

Metodo

I prezzi sono stati raggruppati nelle seguenti classi:

- 20–39 €
- 40–59 €
- 60–79 €
- 80–99 €
- 100–119 €
- 120–139 €

Per ciascuna classe è stata calcolata la frequenza.

Perché creare una distribuzione in classi?

Le frequenze permettono di:

- sintetizzare molti dati;
- individuare le fasce di prezzo più rappresentate;
- osservare eventuali concentrazioni o distribuzioni anomale.

Risultati

Dal conteggio emerge che le classi:

- 40–59 €
- 100–119 €

presentano entrambe la frequenza più elevata.

Interpretazione

La distribuzione può essere considerata bimodale, perché due intervalli presentano la stessa frequenza massima.

Questo suggerisce la presenza di due fasce di prezzo prevalenti nel territorio.

INDIVIDUAZIONE DEGLI OUTLIER

Ricerca dei valori anomali mediante l'IQR

Obiettivo

Verificare se il dataset contiene prezzi estremamente elevati o estremamente bassi.

Metodo utilizzato

È stato applicato il metodo di Tukey.
Si calcolano:

- Primo quartile (Q1)
- Terzo quartile (Q3)
- Intervallo interquartile (IQR)

Successivamente vengono determinati:

Limite inferiore

$Q1 - 1,5 \times IQR$

Limite superiore

$Q3 + 1,5 \times IQR$

Perché utilizzare l'IQR?

L'IQR è poco influenzato dai valori estremi ed è quindi uno degli strumenti più utilizzati per individuare outlier.

Risultati

I limiti calcolati sono:

- Limite inferiore = -27 €
- Limite superiore = 174,25 €

Confrontando questi valori con il dataset si osserva che nessun prezzo supera i limiti individuati.

Interpretazione

Non sono stati individuati outlier secondo il metodo di Tukey.

Ciò significa che il dataset non presenta prezzi eccezionalmente anomali che possano alterare le analisi successive.

CALCOLO DELLE PROBABILITÀ

Analisi probabilistica delle categorie ricettive

Obiettivo

Calcolare la probabilità che una struttura selezionata casualmente appartenga ad una determinata categoria.

Concetto teorico

La probabilità classica si calcola come:
$$P(A) = \frac{\text{Eventi favorevoli}}{\text{Eventi possibili}}$$

dove:

- Eventi favorevoli = numero di strutture della categoria considerata.
- Eventi possibili = numero totale delle strutture.

Nel nostro dataset:

- Totale strutture = 6.258 patrimonio ricettivo.

Esempi svolti

Probabilità di selezionare un Albergo
Formula Excel =814/6258
Risultato $\approx 13,0\%$

Probabilità di selezionare un Bed & Breakfast
Formula =1809/6258
Risultato $\approx 28,9\%$

Probabilità di estrarre due Alberghi consecutivamente (estrazioni indipendenti)
Formula = $(814/6258)^2$

Perché è importante?

Questa analisi permette di stimare la probabilità di osservare determinate categorie all'interno dell'intero

DISTRIBUZIONE NORMALE E REGOLA EMPIRICA

Verifica della distribuzione dei prezzi

Obiettivo

Valutare quanto i prezzi risultano concentrati attorno alla media.

Concetto teorico

Per una distribuzione normale:

- circa 68% dei dati ricade entro ± 1 deviazione standard;
- circa 95% entro ± 2 deviazioni standard;
- circa 99,7% entro ± 3 deviazioni standard.

Questa è nota come regola empirica 68–95–99,7.

Calcoli effettuati

Sono stati determinati:

Intervallo $\pm 1\sigma$

Media $\pm$ Deviazione Standard

Intervallo $\pm 2\sigma$

Media $\pm 2 \times$ Deviazione Standard

Successivamente è stato contato il numero di città appartenenti ai due intervalli.

Risultati

Nel dataset:

- entro $\pm 1\sigma \rightarrow 55,56\%$
- entro $\pm 2\sigma \rightarrow 100\%$

Interpretazione

La distribuzione osservata non coincide perfettamente con una normale teorica.

Tuttavia tutti i dati risultano compresi entro due deviazioni standard, indicando l'assenza di valori estremamente anomali.

Z-SCORE

Standardizzazione dei dati

Obiettivo

Standardizzare i prezzi per misurare quanto ciascun valore si discosta dalla media, espresso in numero di deviazioni standard.

Formula teorica

dove:

- x = prezzo osservato;
- μ = media;
- σ = deviazione standard.

$$Z = \frac{x - \mu}{\sigma}$$

Formula Excel

=(Prezzo-Media)/DeviazioneStandard

Interpretazione

Lo Z-score misura la distanza di un valore dalla media.

Ad esempio:

- $Z = 0 \rightarrow$ valore uguale alla media.
- $Z = 1 \rightarrow$ una deviazione standard sopra la media.
- $Z = -1 \rightarrow$ una deviazione standard sotto la media.

Applicazione al dataset

Per ogni città è stato calcolato:

- lo Z-score del prezzo medio;
- la probabilità cumulata mediante la funzione:

=DISTRIB.NORM.ST(Z;VERO)

per determinare la probabilità cumulata associata allo Z-score.

Questo ha permesso di valutare la posizione di ciascun prezzo rispetto alla distribuzione complessiva.

Perché utilizzare lo Z-score?

Permette di confrontare osservazioni appartenenti alla stessa distribuzione eliminando l'effetto della scala di misura.

INTERVALLO DI CONFIDENZA

Stima della media della popolazione

Obiettivo

Stimare l'intervallo entro cui si trova la vera media dei prezzi della popolazione.

Livello di confidenza

È stato scelto un livello del 95%.

Ciò significa che, ripetendo il campionamento molte volte, il 95% degli intervalli costruiti con lo stesso metodo conterrebbe la vera media della popolazione.

Formula Excel

=CONFIDENZA.NORM(0,05;DeviazioneStandard;NumeroOsservazioni)

Calcoli

Margine di errore



Limite inferiore = Media - Margine

Limite superiore = Media + Margine

Interpretazione

L'intervallo rappresenta una stima plausibile della media reale della popolazione.

Maggiore è il campione, minore sarà il margine di errore.

Effetto della numerosità **campionaria**

Durante l'esercizio è stato confrontato il margine di errore con diverse numerosità campionarie.

È stato osservato che:

- aumentando il numero di osservazioni;
- il margine di errore diminuisce;
- la stima della media diventa più precisa.

TEST D'IPOTESI: CONFRONTO TRA ALBERGHI E AGRITURISMI

Confronto dei prezzi medi mediante t-test

Obiettivo

Verificare se il prezzo medio degli Alberghi è significativamente diverso dal prezzo medio degli Alloggi Agrituristici.

In altre parole, vogliamo capire se la differenza osservata è reale oppure può essere dovuta al caso.

Domanda di ricerca

Gli Alberghi hanno un prezzo medio diverso rispetto agli Alloggi Agrituristici?

Medie osservate

Alberghi = prezzo medio 77,26 €

Alloggi Agrituristici = prezzo medio 68,94 €

Differenza osservata

$77,26 - 68,94 = 8,32$ €

Ipotesi statistiche

Ipotesi nulla (H_0) → $\mu_{\text{Alberghi}} = \mu_{\text{Agriturismi}}$

Significa:

non esiste alcuna differenza significativa tra i prezzi medi.

Ipotesi alternativa (H_1) → $\mu_{\text{Alberghi}} \neq \mu_{\text{Agriturismi}}$

Significa:

esiste una differenza significativa tra le due medie

Test utilizzato

- È stato applicato un t-test per due campioni indipendenti.
- Il t-test confronta le due medie considerando anche:
 - numerosità dei gruppi;
 - variabilità dei dati.

p-value

- Risultato ottenuto = $3,44 \times 10^{-10}$;
ovvero = 0,000000000344

Interpretazione

Poiché $p < 0,05$ l'ipotesi nulla viene rifiutata.

Questo significa che la differenza osservata è statisticamente significativa e difficilmente attribuibile al caso.

CORRELAZIONE E REGRESSIONE LINEARE

Analisi della relazione tra numero di strutture e prezzo medio

Obiettivo

Verificare se esiste una relazione lineare tra il numero di strutture ricettive presenti in una città e il relativo prezzo medio.

In particolare, valutare se all'aumentare del numero di strutture il prezzo medio tende ad aumentare, diminuire oppure rimanere invariato.

Domanda di ricerca

Esiste una relazione statisticamente apprezzabile tra il numero di strutture ricettive e il prezzo medio delle città?

Variabili analizzate

Variabile indipendente (X)

Numero di strutture ricettive presenti nella città.

Variabile dipendente (Y)

Prezzo medio della città.

Strumenti utilizzati

Per analizzare la relazione sono stati utilizzati:

- covarianza;
- coefficiente di correlazione di Pearson (r);
- diagramma di dispersione;
- retta di regressione lineare;
- coefficiente di determinazione (R^2).

Perché questi strumenti?

Consentono di:

- misurare intensità e direzione della relazione tra due variabili quantitative;
- rappresentare graficamente i dati;
- valutare la capacità predittiva della regressione lineare.

Obiettivo finale

Determinare se il numero di strutture costituisce un buon predittore del prezzo medio oppure se le due variabili risultano sostanzialmente indipendenti.

CORRELAZIONE E REGRESSIONE LINEARE

Relazione tra numero di strutture e prezzo medio

Domanda di ricerca

Le città con un numero maggiore di strutture ricettive presentano anche prezzi medi più elevati?

Per rispondere sono stati utilizzati:

- covarianza;
- correlazione;
- regressione lineare;
- coefficiente di determinazione R^2 .
-

Covarianza

Formula Excel =

=COVARIANZA.P(intervallo_numero_strutture;intervallo_prezzi)

Cos'è?

La covarianza misura se due variabili tendono a crescere o diminuire insieme.

- positiva → crescono insieme;
- negativa → una cresce e l'altra diminuisce.

Limite

Il valore dipende dall'unità di misura, quindi da solo è difficile da interpretare.

Correlazione

Formula Excel=

=CORRELAZIONE(intervallo_numero_strutture;
intervallo_prezzi)

Risultato → $r = 0,004049$

Interpretazione

La correlazione assume valori compresi tra -1 e +1.

- +1 → correlazione positiva perfetta
- -1 → correlazione negativa perfetta
- 0 → nessuna correlazione lineare

Nel nostro caso → $r = 0,004049$ è il coefficiente di correlazione di Pearson assume valori compresi tra -1 e +1. Nel nostro caso $r = 0,004049$ è estremamente vicino a zero, indicando l'assenza di una relazione lineare significativa tra il numero di strutture ricettive e il prezzo medio delle città. Quindi non esiste una relazione lineare significativa tra numero di strutture e prezzo medio.

CORRELAZIONE E REGRESSIONE LINEARE

Regressione lineare

È stato costruito un diagramma di dispersione con linea di tendenza lineare per analizzare la relazione tra il prezzo medio (asse X) e il numero di strutture ricettive (asse Y).

L'equazione della retta ottenuta è:

$$y = 0,0075x + 26,192$$

L'intercetta 26,192 rappresenta il valore teorico del numero di strutture quando il prezzo medio è pari a zero. Pur non avendo un significato pratico nel contesto dell'analisi, costituisce il punto di partenza della retta di regressione. La pendenza 0,0075 indica che, all'aumentare di 1 € del prezzo medio, il numero teorico di strutture aumenterebbe di circa 0,0075 unità.

Si tratta di una variazione estremamente ridotta, che evidenzia una relazione lineare praticamente assente tra le due variabili.

Il coefficiente di determinazione R^2 è stato calcolato elevando al quadrato il coefficiente di correlazione ($R^2 = r^2$) e, nel progetto, mediante la formula Excel basata sul valore di correlazione ottenuto.

Il risultato è:

$$R^2 = 0,000016$$

Il coefficiente di determinazione misura la quota della variabilità della variabile dipendente spiegata dal modello di regressione. Nel nostro caso il modello spiega soltanto lo 0,0016% della variabilità osservata, mentre il restante 99,9984% dipende da altri fattori non considerati nell'analisi. Si conclude quindi che il numero di strutture ricettive non rappresenta un buon predittore del prezzo medio delle città e che la regressione lineare non è adatta per effettuare previsioni affidabili in questo contesto.

CONCLUSIONI

Conclusioni dell'analisi

Obiettivi raggiunti

Durante il progetto sono state applicate le principali funzionalità di Excel avanzato e Power Query per trasformare dati grezzi in informazioni utili all'analisi.

Le attività svolte hanno incluso: importazione dei dati pulizia e standardizzazione; Merge delle tabelle; Raggruppamento (Group By); costruzione di un modello dati aggiornabile.

Analisi in Excel

Successivamente sono stati applicati strumenti di analisi statistica e funzioni avanzate, tra cui: CERCA.VERT; statistiche descrittive; distribuzioni di frequenza probabilità; Z-score; intervalli di confidenza; test d'ipotesi; correlazione; regressione lineare.

Principali risultati

- Il dataset è stato trasformato in un modello dati pulito, coerente e facilmente aggiornabile.
- I prezzi medi delle strutture presentano una distribuzione complessivamente equilibrata, senza evidenza di valori anomali rilevanti.
- Il confronto statistico ha evidenziato una differenza significativa tra il prezzo medio degli Alberghi e quello degli Alloggi Agrituristici.
- L'analisi di correlazione e regressione ha mostrato che il numero di strutture ricettive non costituisce un buon predittore del prezzo medio delle città.

Competenze sviluppate

Questo progetto ha consentito di consolidare competenze relative a: Power Query (processi ETL); preparazione e modellazione dei dati; funzioni di ricerca e collegamento tra tabelle; analisi statistica descrittiva; inferenza statistica; interpretazione critica dei risultati; visualizzazione e rappresentazione grafica dei dati.